

Enjeux sociaux — 2M

Introduction à l'intelligence artificielle

Objectifs du cours

- Distinguer programmation classique et apprentissage automatique.
- Décrire ce que signifie « apprendre » pour une machine.
- Expliquer comment un modèle de langage produit du texte.
- Identifier des limites et enjeux importants de l'IA.

Introduction

Demandez à un assistant un poème : le texte arrive en quelques secondes, fluide et presque juste. Question simple, réponse difficile : que se passe-t-il exactement entre la question et la réponse ? Nous allons explorer le fonctionnement de ces machines afin d'en comprendre les grands principes de fonctionnement : de l'arithmétique, une quantité de données difficile à se représenter, et une opération élémentaire répétée un très grand nombre de fois.

Programmation classique

En **programmation classique**, une personne écrit **les règles** à suivre. Le programme applique ces règles à des données puis fournit un résultat.



Exemple :

```
SI message CONTIENT "vous avez gagné" ET message CONTIENT "cliquez ici"
ALORS
DÉBUT SI
    marquer_comme_spam()
FIN SI
```

Cette approche fonctionne parfaitement tant que le problème peut se décrire par des règles explicites.

Exercice 1

Écrivez la règle qui permettrait de distinguer la photo d'un chat de celle d'un chien. Une règle utilisable par une machine, qui ne reçoit rien d'autre que des couleurs de pixels, donc pas « il a des moustaches ».

.....

.....

.....

.....

.....

Apprentissage automatique (*Machine Learning*)

En **apprentissage automatique** (machine learning), les règles ne sont plus fournies. Ce qui est fourni, ce sont des exemples accompagnés des bonnes réponses (des milliers de photos « étiquetées ») et une procédure d'entraînement qui cherche seule les réglages permettant de retrouver ces réponses.



Exemples : image
image + étiquette



Modèle entraîné



Prédiction sur un
un nouvel exemple

Exemple : reconnaître un chiffre manuscrit. Il est difficile d'écrire toutes les règles possibles, mais on peut fournir de nombreux chiffres déjà annotés.

Exercice 2

Cochez l'approche la plus adaptée pour chaque tâche.

Tâche	Programmation classique	Apprentissage automatique
Calculer la moyenne des notes d'une classe	☐	☐
Détecter si une photo contient un chat	☐	☐
Convertir des degrés Celsius en degrés Fahrenheit	☐	☐
Recommander une chanson selon les écoutes précédentes	☐	☐

Deep Learning : apprendre avec plusieurs couches

Le **deep learning** est une famille de méthodes d'apprentissage automatique qui utilise des réseaux de **neurones artificiels** organisés en plusieurs **couches**. Chaque couche travaille sur le résultat de la précédente et monte d'un cran en abstraction. Le mot « profond » indique simplement qu'il y a plusieurs couches de calcul, pas que la machine comprend le monde comme un humain.




Schéma de neurone biologique





Schéma de neurone artificiel (Perceptron)

Les paramètres d'un neurone


entrées



- 1** les poids
importance de chaque entrée
- 2** le biais
décalage ajouté à la somme
- 3** l'activation
décide de ce qui ressort

Plusieurs **paramètres** permettent de modifier le comportement du neurone artificiel.

Exemple trivial de fonctionnement : décider de sortir ou non un soir de semaine ?



Important

Un modèle n'est pas programmé règle par règle : il est entraîné. Ce qu'il « sait » est stocké dans des nombres, non dans des phrases. Les règles ne sont pas clairement visibles.

Entraîner la machine, c'est ajuster les poids des couches des neurones

Pendant l'entraînement, le modèle fait une prédiction, compare cette prédiction à la réponse attendue, puis modifie de nombreux paramètres internes, principalement les **poids**. L'objectif est de réduire l'erreur, exemple après exemple.






FIGURE 1 – Processus d'entraînement d'un réseau de neurones (source : Canva IA)

Un algorithme de minimisation d'erreur : la descente de gradient

La **descente de gradient** est un algorithme qui aide à choisir de petits ajustements allant dans le sens d'une erreur plus faible. Il ne garantit pas à lui seul un modèle juste ou sans biais.






Les données comptent autant que le modèle

Le modèle ne dispose d'aucune source en dehors de ses exemples. Deux conséquences suivent directement :

- Quantité : avec trop peu d'exemples, aucune régularité fiable ne peut être dégagée.
- Qualité et diversité : pour couvrir tous les cas de figure.

Exemple de biais possible



Exercice 3

En 2025, une étude a montré que des générateurs d'images représentaient presque toujours « un chirurgien » par un homme blanc. Expliquez la raison possible de ce biais ? Comment les réduire ?

Référence : [Associated Press, 2025](#).

.....

.....

.....

Les LLM : prédire la suite d'un texte

Les grands modèles de langage (*Large Language Models*, ou **LLM**) constituent une catégorie de modèles d'apprentissage profond **entraînés à l'aide d'immenses quantités de données** pour comprendre et générer des textes en langage naturel.

Les LLM fonctionnent comme des machines de **prédiction statistique** géantes qui prédisent à plusieurs reprises le mot suivant dans une séquence. Ils apprennent des schémas et génèrent un langage qui suit ces schémas.

Ils demandent un *prompt* en entrée, un texte découpé en **tokens** (des morceaux de mots) qu'ils vont chercher à compléter.

Comment fonctionne une IA générative ?

FIGURE 2 – Un prompt constitué de ses tokens

Du texte aux représentations

- 1 le texte est découpé en tokens




Un token n'est ni un mot ni une lettre : c'est un fragment fréquent, doté d'un numéro.
(Ici un fragment de mot, un sous-mot)

- 2 chaque token devient une suite de nombres

0,42	-0,9	1,06	-0,2	-0,2	0,55	0,99	-1,0	-1,0	-1,5	-1,3	-1,5
-1,7	0,31	0,77	-1,1	-1,1	0,19	-0,8	0,2	1,5	-0,9	-1,2	-0,3
0,08	1,24	-0,4	-0,4	0,63	-1,3	1,12	1,5	3,8	4,7	-1,7	-1,2
...	...	...	...	...	...	...	...	...	...	...	...

Des milliers de valeurs par token **sans rapport avec aucune notion de français**

- 3 les couches : le contexte entre en jeu




Répété sur des dizaines de couches.
« avocat » n'a pas la même représentation dans « un avocat mûr » et dans « mon avocat plaidera ».

Du token à la représentation vectorielle

Les vecteurs de mots (embeddings) sont une façon pour une IA de transformer du texte en vecteurs numériques qu'elle peut comprendre et comparer. En résumé, ils aident l'IA à "comprendre" le sens plutôt que seulement les mots.

Exemple

roi - homme + femme $\approx$ reine



Représentation des mots dans un espace multidimensionnel

Génération du texte et température

Une fois le prompt analysé. Le modèle a pour objectif de prédire le token suivant afin de générer, de proche en proche la réponse complète.


Le modèle ne choisit pas toujours le token le plus probable. La **température** règle le degré de variété des choix.

- Une température basse rend généralement la réponse plus prévisible ;
- une température élevée produit des choix plus variés, mais aussi parfois moins pertinents.

De la prédiction au mot suivant

- 4 une probabilité pour chaque token possible

« L'éléphant dort dans la _____ »



Une valeur pour chacun des
~100 000 tokens du vocabulaire.

Le modèle choisit un token, pas un mot : « savane » en demande trois : « sa », « va », « ne ».

- 5 la température règle le tirage du token suivant



C'est pourquoi la même question ne donne pas deux fois exactement la même réponse.

- 6 le token retenu est ajouté, puis tout recommence

« L'éléphant dort dans la sa_____ »

on repart prédire le token suivant...

Comment un LLM est-il entraîné ?

L'entraînement se déroule en plusieurs étapes complémentaires.

1. **Pré-entraînement** : réglage des poids du modèle pour prédire le token suivant à très grande échelle.
2. **Réglage par instructions** (fine-tuning) : Apprendre avec des exemples « demande / réponse attendue ».
3. **RLHF** (*Reinforcement Learning from Human Feedback*), apprentissage par renforcement à partir de retours humains.

RLHF 

Réglage par instructions

Important

Même si durant le **RLHS** comparent les réponses proposées, cela ne rend pas les réponses automatiquement vraies, neutres ou sans risque.



Pré-entraînement

Exercice 6

Voici une liste présentant 4 limites des LLM. Pour chaque cas, vous expliquerez la raison technique qui en est la cause.

Hallucinations

Une IA générative peut produire une information fausse avec un ton convaincant.

Biais

Un modèle peut reproduire ou amplifier des biais présents dans ses données.

Impact écologique

Entraîner et utiliser de grands modèles consomme de grandes quantités d'électricité et de ressources (minerais pour concevoir les circuits électroniques notamment).

Raisonnement limité

Une réponse cohérente n'est pas une preuve de compréhension ou de vérité.

À retenir

Contrairement à un programme classique, une IA générative (provenant de l'apprentissage automatique) n'applique pas des règles écrites explicitement par un humain : elle produit une réponse à partir de ce qu'elle a appris dans ses données. Son fonctionnement interne reste donc difficile à expliquer précisément.

Il est essentiel de connaître ses limites avant de l'utiliser : elle peut notamment produire des informations fausses, reproduire des biais ou donner une impression de raisonnement sans réellement comprendre. De plus, son entraînement et son utilisation ont un impact environnemental non négligeable.

Sources

- *Comment fonctionne une IA générative ?*, A.D. Martin
- Illustrations, chatGPT, GPT-5.6 Terra